

ChatEV

Predicción de Demanda de Recarga de Vehículos Eléctricos mediante Modelos de Lenguaje

Modelado Computacional, Simulación y Optimización

Autoras: Jimena Milla, Itsaso Ariztimuño



Motivación y Objetivos

El Problema

La movilidad eléctrica crece rápidamente, pero los modelos tradicionales de predicción de demanda no capturan la complejidad espaciotemporal de la recarga urbana.

La Solución Propuesta

ChatEV reformula la predicción como generación de lenguaje natural, unificando contexto espacial, temporal y externo en un único prompt para un LLM.

Objetivos de Replicación

Replicar ChatEV, evaluar Full-Shot / Zero-Shot / Few-Shot, analizar Reptile e integrar datos contextuales externos.

Dataset ST-EVCDP



Shenzhen, China

19 junio - 18 julio de 2022

Dataset espaciotemporal de ocupación de puntos de carga públicos, disponible en el repositorio oficial de IntelligentSystemsLab.

247 zonas TAZ

Con infraestructura de carga real

18.061 puntos

Cargadores públicos

8.640 timesteps

30 días · intervalo de 5 min

Datasets extra que hemos encontrado para enriquecer el modelo



Meteorología

API: Open-Meteo

Variables:

- temperatura
- humedad
- precipitación
- velocidad
- viento

Direcciones postales

API: Nominatim (OpenStreetMap)

Reverse geocoding de coordenadas
cdentroide de cada TAZ →
dirección postal



Usada en el texto del prompt
para contextualizar la zona

Features de calendario


Librería: chinese-
calendar

Festivos chinos, hora
pico, codificación cíclica
(seno/coseno de hora y
día)

VISUALIZACIÓN ESPACIAL: Integración de SZ_districts.shp con los datasets del proyecto.



Distribución de infraestructura VE por distrito




name	n_stations	n_fast	n_slow	total_puntos
Longgang District	395	532	5108	5640
Nanshan District	315	217	4001	4218
Futian District	262	42	2562	2604
Bao'an District	246	872	3244	4116
Luohu District	174	217	1539	1756
Longhua District	147	326	1980	2306
Guangming District	46	235	433	668
Pingshan District	40	156	588	744
Yantian District	34	2	322	324
Dapeng New District	11	0	187	187

Mapa interactivo usando la librería Folium

Enlace:

https://drive.google.com/file/d/1PydnW5p9cszp67GA-_0P6EOAdtgdNtuV/view?usp=share_link



Preprocesado y División de Datos

Flujo de preprocesado

→ Normalización Min-Max por zona


Ajustada solo con datos de entrenamiento para evitar filtraciones.

→ Graph Message Passing

Ocupación media de zonas vecinas calculada desde la matriz de adyacencia (503 aristas).

→ División cronológica

Train 60% · Val 20% · Test 20%



198 zonas vistas y 49 no vistas (~20%) para evaluar generalización espacial (zero-shot).

Reformulación Text-to-Text e Ingeniería del Prompt

Cada muestra se codifica como texto natural. El LLM genera un único token decimal **[0, 1]** como predicción de ocupación.

Ejemplo de prompt generado:

"You are an expert in electric vehicle charging management, who is good at <charging demand prediction>. We are now in Area ID=106, Coordinates=[22.6715N, 113.9909E], Address=N/A, Area Type=Non-CBD, Total Piles=6 (0 fast / 6 slow), Pricing=flat-rate pricing, Weather=[26.4°C, humidity 95%, dry], Time=[Wednesday night, Weekday, off-peak]. Given the following time series of historical charging data, [...]"

Variables del prompt

- **Estáticas:** coordenadas, tipo de zona, nº cargadores, precio, dirección postal
- **Dinámicas:** ocupación local y vecina, precio, duración (lookback 12 pasos)
- **Externas:** temperatura, humedad, periodo del día, día de semana, hora pico

Meta-Aprendizaje Reptile

Algoritmo de primer orden que encuentra una inicialización θ del LLM capaz de adaptarse rápidamente a nuevas zonas con pocos pasos de gradiente.

Proceso de Reptile:

1. Dividir el conjunto de datos de cada zona en **Support Set** y **Query Set**.
2. En cada época, muestrear aleatoriamente una zona i .
3. Ejecutar **S pasos de SGD** (con optimizador Adam) sobre el Support Set de la zona, partiendo de los parámetros actuales θ , obteniendo parámetros temporales ϕ .
4. Ejecutar **1 paso de SGD** sobre el Query Set a partir de ϕ , obteniendo $\hat{\theta}$.
5. Actualizar la inicialización global: $\theta \leftarrow \theta + \varepsilon \cdot (\hat{\theta} - \theta)$.



Early stopping en época 30 (patience=7). Mejor **Negative Log-Likelihood** (NLL) = 0.077 en época ~23. Inestabilidad post-época 20 por muestreo de tareas.

Support Set → Adaptación local

S=3 pasos SGD por zona muestreada

Query Set → Dirección de actualización

1 paso SGD para obtener $\hat{\theta}$

Actualización global

$\theta \leftarrow \theta + \varepsilon \cdot (\hat{\theta} - \theta)$, $\varepsilon=0.1$

Integración de Datos Externos



Open-Meteo ✓

Temperatura, humedad y precipitación horarias interpoladas a 5 min. Temp. media: 27,7°C · Humedad: 85%.



Chinese Calendar ✓

Festivos oficiales chinos, hora pico, codificación cíclica. Sin festivos en el periodo estudiado.



Nominatim / OSM ✓

Geocodificación inversa de las 247 zonas. Direcciones en mandarín con distrito y ciudad.




POI & Road Length ✗

No disponibles en los CSVs públicos. Principal limitación respecto al paper original.

ChatEV vs. Baseline Histórico

Métricas MAE y RMSE ($\times 10^{-2}$) en el escenario **Full-Shot** (198 zonas vistas, intervalo de 30 min). El baseline histórico supera a ChatEV en esta configuración, como se detalla en la discusión.



ChatEV — MAE

5,31 $\times 10^{-2}$

ChatEV — RMSE

10,87 $\times 10^{-2}$

Baseline — MAE


4,37 $\times 10^{-2}$

Baseline — RMSE

7,96 $\times 10^{-2}$

Generalización a Zonas No Vistas

Evaluación sobre **49 zonas no vistas** sin fine-tuning adicional. La diferencia con el paper se explica principalmente por el backbone reducido (T5-small).



ChatEV — MAE

$11,32 \times 10^{-2}$ · RMSE: $18,17 \times 10^{-2}$

Baseline — MAE

$7,28 \times 10^{-2}$ · RMSE: $11,23 \times 10^{-2}$

Factor de diferencia


MAE: **3,13×** respecto al paper

Replicación vs. Paper Original

Comparativa de MAE y RMSE ($\times 10^{-2}$) entre la replicación (T5-small) y el paper original (Sentence-T5). La brecha es más acusada en Zero-Shot.

MAE Replicación

MAE Paper



Full-Shot

MAE: 5,31 vs. 3,29

Factor: **1,61×**

Zero-Shot

MAE: 11,32 vs. 3,61

Factor: **3,13×**

Causa principal


Backbone T5-small (60,5M params) vs. Sentence-T5 completo

Rendimiento con Datos Limitados

Fine-tuning con 5%, 10%, 15% y 20% de los timesteps de entrenamiento (3 épocas adicionales). El MAE de la replicación es **mejor** que el del paper.

MAE Replicación

MAE Paper



MAE promedio
replicación

$2,38 \times 10^{-2}$ vs. 3,49 del paper

RMSE promedio
replicación


$5,47 \times 10^{-2}$ vs. 5,68 del paper

Interpretación

El T5-small puede sobreajustarse más rápidamente con pocos datos en 3 épocas de fine-tuning.

Contribución de Cada Componente

El estudio de ablación evalúa la contribución de cada componente eliminándolo por separado. **Reptile es el componente más crítico**: sin él, el MAE se multiplica por 3,9×.



ChatEV completo

MAE: $5,31 \times 10^{-2}$

Sin Prompting

MAE: $6,02 \times 10^{-2}$

Incremento moderado (+13%)

Sin Reptile

MAE: $20,62 \times 10^{-2}$

Incremento crítico (3,9×)

¿Qué son Zero-Shot y Few-Shot?



ChatEV evalúa dos escenarios clave de generalización espacial sobre el dataset ST-EVCDP (247 zonas, Shenzhen).

Zero-Shot

Predicción en **49 zonas nunca vistas** (~20% del total), sin ningún fine-tuning previo. Demuestra generalización espacial pura.

Few-Shot

Fine-tuning con fracciones reducidas de datos: **5%, 10%, 15% y 20%** de los timesteps de entrenamiento. Evalúa adaptación rápida.

Protocolo Zero-Shot

01

Reserva inicial

49 zonas unseen (~20%) se excluyen desde el inicio de todo el meta-entrenamiento Reptile.

03


Sin adaptación

Los pesos Reptile **nunca se actualizan** con datos de las 49 zonas reservadas. La normalización Min-Max se ajusta solo sobre train.


02

Inferencia idéntica

Se construye el prompt completo (historial local, vecinos SGC, precio, duración) y se aplica decodificación greedy.



Resultados Zero-Shot



MAE en escenario Zero-Shot ($\times 10^{-2}$)

La réplica obtiene MAE **11,32** frente a **3,61** del paper — una brecha de **3,13×**. El baseline histórico en ambos casos es 7,28.



La diferencia se atribuye principalmente al backbone reducido (T5-small vs. Sentence-T5) y a solo 30 épocas de entrenamiento.

¿Por qué funciona el Zero-Shot en ChatEV?

Tres componentes hacen posible predecir en zonas sin datos previos:



Meta-aprendizaje Reptile

Aprende una inicialización generalizable: el modelo *razona* sobre patrones de carga, no memoriza zonas concretas.



Prompt geoespacial

Coordenadas, tipo CBD, vecinos (SGC), precio y duración aportan contexto semántico suficiente sin fine-tuning previo.



Simple Graph Convolution

La ocupación media de zonas vecinas viaja en el prompt aunque la zona target sea unseen, anclando la predicción al entorno local.

Protocolo Few-Shot

Replica la **Sección 4.2.2 y Tabla 3** del paper. El fine-tuning few-shot usa **3 épocas adicionales** ($\text{lr}=1\text{e-4}$, $\text{batch}=8$) sobre el modelo Reptile ya entrenado.

5%

4.158 muestras train

10%


8.316 muestras train

15%


12.672 muestras train

20%

16.830 muestras train



Resultados Few-Shot




MAE comparativo por ratio ($\times 10^{-2}$)

Sorprendentemente, la réplica obtiene MAE **mejores** que el paper en todos los ratios (promedio: **2,38** vs. **3,49**).

El RMSE es comparable: **5,43-5,57** (réplica) vs. **5,49-5,84** (paper), sugiriendo varianza de errores similar.

📄 ChatEV supera ampliamente a ARIMA, LSTM y HSTGCN en few-shot, gracias al meta-aprendizaje Reptile.

Comparativa de Degradación: Full-Shot → Zero-Shot



Incremento de error al pasar a zero-shot

Paper: +9,7%

De 3,29 a 3,61 —
degradación mínima
gracias a Sentence-T5
completo y hasta 200
épocas.

Réplica: +113%

De 5,31 a 11,32 —
brecha **3,13× mayor**
que la del paper.

Arquitectura del Sistema Gradio



La interfaz Gradio materializa la visión del paper: ChatEV como predictor conversacional de demanda de recarga. El modelo se guarda en Google Drive y se carga sin reentrenamiento en cada sesión.

LA INTERFAZ DE CHAT

- Para ahorrar tiempo reentrenando el modelo, tenemos sus pesos disponibles en nuestra carpeta de Google Drive, accesible desde el siguiente enlace: https://drive.google.com/drive/folders/1vGVgg-Ka674ut6XXrAAuXLcOetpl2A?usp=share_link
- De esta forma, basta con descargarlos y ejecutar el script de la interfaz, creado con Gradio.
- El enlace público dura una semana y es: <https://2933a2f0033c00854f.gradio.live>

ChatEV — EV Charging Demand Predictor

Predice demanda de recarga EV en lenguaje natural. Escribe **zona <ID>** (0-246) o el número directamente. Escribe **help** para instrucciones. *T5-small · Reptile · ST-EVCDP Shenzhen 2022*

 Chatbot

Zona 42 — 2022-07-16 00:15

 NO VISTA (zero-shot)

Predicción ChatEV (próximos 30 min): 0.40

	Valor
Predicción	0.4000
Valor real (test)	0.7143
Error absoluto	0.3143
Ocupación reciente (media 3 pasos)	0.7143
Tendencia	↓ bajando

Ventana: 12 pasos (1h) · Horizonte: 6 pasos (30min)



Type a message...



Predice la demanda eléctrica
en la zona 42

Predicción ChatEV (próximos 30
min): 0.4

Aspectos Replicados y Extensiones

Replicado del Paper

- Dataset ST-EVCDP (247 zonas, 8640 timesteps)
- Reformulación text-to-text con prompts
- Role-playing (zero-shot augmentation)
- Graph Message Passing para vecinos
- Meta-aprendizaje Reptile (Support + Query)
- Evaluación Full / Zero / Few-Shot

Extensiones Propias

- Datos meteorológicos (Open-Meteo)
- Calendario (incluye calendario chino)
- Reverse geocoding (Nominatim)
- Interfaz conversacional Gradio

LIMITACIONES

Factores que Explican la Brecha de Rendimiento



Backbone reducido

T5-small (60,5M params) vs. Sentence-T5 completo.
Limita la comprensión semántica y la generalización.



Menos épocas de entrenamiento

30 épocas vs. hasta 200 del paper. Hardware: GPU T4 (Colab) vs. 2× RTX 3090.



Features espaciales incompletas

Road Length y POI Density no disponibles en los CSVs públicos. Prompt menos informativo.



Evaluación reducida

MAX_EVAL = 300 muestras para eficiencia computacional. Métricas estadísticamente menos robustas.

CONCLUSIONES

Conclusiones Clave

ChatEV es reproducible

La arquitectura text-to-text con Reptile es viable incluso con recursos computacionales limitados.

Reptile es el componente crítico

Sin meta-aprendizaje, el MAE se multiplica por 3,9×. Es el mayor contribuyente al rendimiento.

Text-to-Text funciona para demanda VE

El enfoque de lenguaje natural para predicción temporal de carga es válido y generaliza mejor que baselines estadísticos.

La brecha se explica por el backbone

T5-small vs. Sentence-T5 es la causa principal de la diferencia de métricas, no errores metodológicos.

TRABAJO FUTURO

Líneas de Investigación Futuras

- **Sentence-T5 completo**
Reemplazar T5-small por el backbone original del paper para mejorar la capacidad semántica.
- **Más épocas y datos espaciales**
Incorporar POI Density, Road Length y features espaciales avanzadas al prompt.
- **Escalado del experimento**
Evaluar sobre más zonas, intervalos temporales y escenarios de generalización.